Laboratorium nr 2 – Podstawowe algorytmy przetwarzania tekstu

Zadanie na 3.0

a)

Pobierz przykładowa ksiażke w formacie `.txt` ze strony `https://wolnelektury.pl` lub jakiś inny tekst literacki.
Na przykład: `https://wolnelektury.pl/media/book/txt/pan-tadeusz.txt`.

Wczytaj tekst w Pythonie i oczyść go (usuń znaki specjalne, zamień litery na małe). Wygeneruj:

a) unigramy (pojedyncze słowa),

b) bigramy (pary słów),

c) trigramy (trójki słów).

Policz czestość wystepowania n-gramów przy pomocy `collections.Counter` lub `nltk`. Zrób histogram najcześciej wystepujacych n-gramów (np. 10 najczestszych bigramów i trigramów) z wykorzystaniem biblioteki `matplotlib`.
Odpowiedz na pytania:

a) Jakie bigramy dominuja w analizowanym tekście?

b) Czy trigramy pokazuja powtarzalne zwroty charakterystyczne dla autora?

c) Jak różni sie rozkład unigramów od bigramów?

b)

Dysponujesz zdaniami: „Ala ma kota" oraz „Ala posiada kota".
Na podstawie biblioteki `textdistance` zbadaj odległość Levenshteina. Wyjaśnij uzyskany wynik.
Na teams prześlij archiwum `.zip`, które bedzie miało nazwe:
LAB2_Nazwisko_Imie_Nazwisko_Imie.zip
Archiwum powinno zawierać wybrany plik `.txt` z tekstem literackim oraz kody źródłowe w jezyku Python. Zadanie na 3.0 nie wymaga odpowiedzi ustnej ze sprawozdania.

Zadanie na 4.0

a)

Pobierz przykładowa ksiażke w formacie `.txt` ze strony `https://wolnelektury.pl` lub inny tekst literacki.
Na przykład: `https://wolnelektury.pl/media/book/txt/pan-tadeusz.txt`.

Wczytaj tekst w Pythonie i oczyść go (usuń znaki specjalne, zamień litery na małe). Wygeneruj:

a) unigramy (pojedyncze słowa),

b) bigramy (pary słów),

c) trigramy (trójki słów).

Policz czestość wystepowania n-gramów przy pomocy `collections.Counter` lub `nltk`. Zrób histogram najcześciej wystepujacych n-gramów (np. 10 najczestszych bigramów i trigramów) z wykorzystaniem biblioteki `matplotlib`.
Odpowiedz na pytania:

a) Jakie bigramy dominuja w analizowanym tekście?

b) Czy trigramy pokazuja powtarzalne zwroty charakterystyczne dla autora?

c) Jak różni sie rozkład unigramów od bigramów?

b)

Dysponujesz zdaniami: „Ala ma kota" oraz „Ala posiada kota".
Na podstawie biblioteki `textdistance` zbadaj odległość Levenshteina. Wyjaśnij uzyskany wynik.
Dodatkowo wybierz jeszcze 3 miary z tej biblioteki, wyjaśnij zasade ich działania i porównaj rezultaty z odległościa Levenshteina.
Na teams prześlij archiwum `.zip`, które bedzie miało nazwe:
LAB2_Nazwisko_Imie_Nazwisko_Imie.zip
Archiwum powinno zawierać wybrany plik `.txt` z tekstem literackim oraz kody źródłowe w jezyku Python. Dodatkowo powinno zawierać sprawozdanie w formacie PDF zawierajace:

a) Analize uzyskanych histogramów,

b) Odpowiedzi na pytania,

c) Zasady działania algorytmów odległości edycyjnej i porównanie wyników osiagnietych przez poszczególne algorytmy.

Prześlij `.zip` w terminie i podejdź do odpowiedzi ustnej na najbliższych laboratoriach.

Zadanie na 5.0

a)

Pobierz przykładowa ksiażke w formacie `.txt` ze strony `https://wolnelektury.pl` lub inny tekst literacki.
Na przykład: `https://wolnelektury.pl/media/book/txt/pan-tadeusz.txt`.

Wczytaj tekst w Pythonie i oczyść go (usuń znaki specjalne, zamień litery na małe). Usuń stopwords.
Wygeneruj:

a) unigramy (pojedyncze słowa),

b) bigramy (pary słów),

c) trigramy (trójki słów).

Policz czestość wystepowania n-gramów przy pomocy `collections.Counter` lub `nltk`. Zrób histogram najcześciej wystepujacych n-gramów (np. 10 najczestszych bigramów i trigramów) z wykorzystaniem biblioteki `matplotlib`.
Odpowiedz na pytania:

a) Jakie bigramy dominuja w analizowanym tekście?

b) Czy trigramy pokazuja powtarzalne zwroty charakterystyczne dla autora?

c) Jak różni sie rozkład unigramów od bigramów?

d) Porównaj analize n-gramów z usunietymi stopwords i bez nich. Czy sa istotne różnice?

b)

Dysponujesz zdaniami: „`Ala ma kota"` oraz „`Ala posiada kota"`.
Na podstawie biblioteki `textdistance` zbadaj odległość Levenshteina. Wyjaśnij uzyskany wynik.
Dodatkowo wybierz jeszcze 5 miar z tej biblioteki, wyjaśnij zasade ich działania i porównaj rezultaty z odległościa Levenshteina.

c)

W tekście z podpunktu A dokonaj analizy nazw własnych (w jezyku polskim łatwo je znaleźć – zaczynaja sie od wielkiej litery).
Wskaż 10 najcześciej wystepujacych nazw własnych. Zwróć uwage, by to słowo nie było na poczatku zdania (w środku zdania i wielka litera – wieksza szansa, że to nazwa własna). Zrealizuj zadanie z wykorzystaniem wyrażeń regularnych.
Na teams prześlij archiwum `.zip`, które bedzie miało nazwe:
LAB2_Nazwisko_Imie_Nazwisko_Imie.zip
Archiwum powinno zawierać wybrany plik `.txt` z tekstem literackim oraz kody źródłowe w jezyku Python. Dodatkowo powinno zawierać sprawozdanie w formacie PDF zawierajace:

a) Analize uzyskanych histogramów,

b) Porównanie wyników z usunieciem stopwords i bez ich usuwania,

c) Odpowiedzi na pytania,

d) Zasady działania algorytmów odległości edycyjnej i porównanie wyników osiagnietych przez poszczególne algorytmy,

e) Omówienie wyrażenia regularnego i wyników z zadania c).

Prześlij `.zip` w terminie i podejdź do odpowiedzi ustnej na najbliższych laboratoriach.