Laboratorium nr 6 – Generowanie Języka Naturalnego (cz. 1)

Zadanie na 3.0

Wybierz dowolny tekst literatury zagranicznej, np. *Przygody Sherlocka Holmesa* (link), oraz dowolny tekst literatury polskiej, na przykład *Lalka* (link).

Dla obu tych tekstów wykorzystaj n-gramowy model generowania tekstu bazując na modelu MLE. Wykorzystaj n-gramy dla $n = 1$, $n = 2$ oraz $n = 3$. Wygeneruj po 100 kolejnych słów.

Jako *seed* (który musi istnieć w korpusie) możesz wybrać dowolne słowa z tekstów lub wziąć ostatnie słowa z pozycji literackiej. Zapisz do plików `.txt` to, co udało Ci się wygenerować. Jak oceniasz osiągnięte wyniki?

Przeprowadź dodatkową analizę i wykorzystaj 10%, 50%, 80% i 100% części wybranych tekstów. Jak oceniasz działanie modeli w takich scenariuszach?

Na platformie Teams wyślij archiwum `.zip` o nazwie:
`LAB6_Nazwisko_Imie_Nazwisko_Imie.zip`

Archiwum powinno zawierać pliki `.txt` z tekstami literackimi, wygenerowane teksty w plikach `.txt` oraz kod źródłowy w języku Python. Zadanie na 3.0 nie wymaga odpowiedzi ustnej ze sprawozdania.

Zadanie na 4.0

Wczytaj do modelu trochę poezji Mickiewicza, trochę rapu Paktofoniki i trochę wierszy Edwarda Stachury (możesz też wybrać innych artystów, którzy są dla Ciebie ważni). Wygeneruj z tego 5 nowych wierszy.

Na platformie Teams wyślij archiwum `.zip` o nazwie:
`LAB6_Nazwisko_Imie_Nazwisko_Imie.zip`

Archiwum powinno zawierać pliki `.txt` z tekstami literackimi, wygenerowane teksty w plikach `.txt` oraz kod źródłowy w języku Python, a także sprawozdanie w formacie `.pdf` z podsumowaniem przeprowadzonych eksperymentów. Prześlij `.zip` w terminie i podejdź do odpowiedzi ustnej na najbliższych laboratoriach.

Zadanie na 5.0

Zrealizuj zadania na 4.0 bazując także na modelach Laplace oraz Kneser–Ney smoothing.

Na platformie Teams wyślij archiwum `.zip` o nazwie:
`LAB6_Nazwisko_Imie_Nazwisko_Imie.zip`

Archiwum powinno zawierać pliki `.txt` z tekstami literackimi, wygenerowane teksty w plikach `.txt` oraz kod źródłowy w języku Python, a także sprawozdanie w formacie `.pdf` z podsumowaniem przeprowadzonych eksperymentów oraz szczegółowym opisem algorytmów MLE, Laplace i Kneser–Ney smoothing. Prześlij `.zip` w terminie i podejdź do odpowiedzi ustnej na najbliższych laboratoriach.