Przetwarzanie języka naturalnego

Laboratorium nr 7

Dr inż. Wojciech Książek

Wydział Informatyki i Telekomunikacji
Katedra Informatyki
Politechnika Krakowska
Kraków 2025

Generowanie języka naturalnego

- W ramach tego laboratorium skupimy się na innym podejściu do generowania języka naturalnego

- Wykorzystamy do tego rekurencyjne sieci neuronowe

Znakowa sieć rekurencyjna

- ang. character RNN, w skrócie char-RNN

- Taka sieć będzie miała za zadanie przewidzieć następny znak w zdaniu

- W pierwszym wariancie wykorzystamy bezstanową sieć rekurencyjną (ang. stateless RNN, w każdej iteracji poznaje ona losowe fragmenty tekstu, bez dostępu do informacji na temat reszty tekstu)

- Pierwsza taka koncepcja: Andrej Karpathy, rok 2015, The unreasonable effectiveness of recurrent neural networks https://karpathy.github.io/2015/05/21/rnn-effectiveness/

- Można by to nazwać jednym z pierwszych modeli językowych, a współczesne modele bazują na tym podejściu

Model McCullocha-Pittsa (1943)

- Pierwszy model neuronu

- Sygnały wejściowe mogą mieć wartość 0 lub 1

- Wagi początkowe mogą mieć wartości -1 lub 1

- Wyjście ma postać:

y^j = 1 gdy $\sum_{i=1}^{n} w_i x_i^j + w_0 >= 0$
0 gdy $\sum_{i=1}^{n} w_i x_i + w_0 < 0$

- w_0 - bias uwzględniający błąd systematyczny w neuronach wejściowych

Gdzie, y^j to wyjście dla j-tej próbki, x_i^j wartość i-tej cechy, dla j-tej próbki, w_i - wartość i-tej wagi

X = $[X_1, X_2, \ldots, X_p]$, wektory próbek uczących , $x_i \in X$

W = $[w_1, w_2, \ldots, w_n]$, $w_i \in W$

Perceptron Rossenblata (1958)

- Model McCullocha-Pittsa wraz ze strategią uczenia

- Pobudzenie neuronu (potencjał wewnętrzny)

e = $\sum_{i=1}^{n} w_i x_i^j + w_0 = \sum_{i=0}^{n} w_i x_i^j$ = W * X^T

X = [$X_1, X_2, \ldots, X_p$] , $x_i \in X$ – wektory próbek uczących , $x_i \in X$

Z = [$z_1, z_2, \ldots, z_p$] – oznaczenia (klasy) próbek uczących

W = [$w_0, w_1, \ldots, w_n$], $w_i \in W$

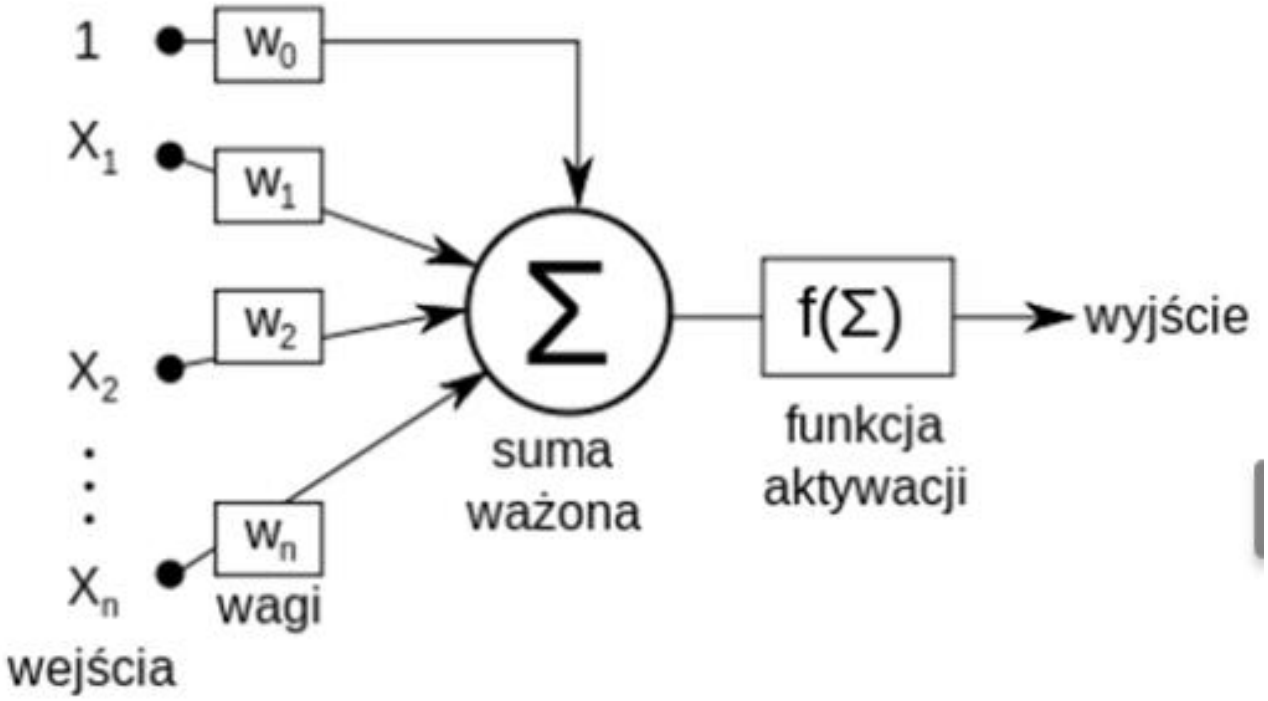
- Wyjście neuronu – funkcja signum

y^j = 1 gdy e >=0
0 gdy e < 0

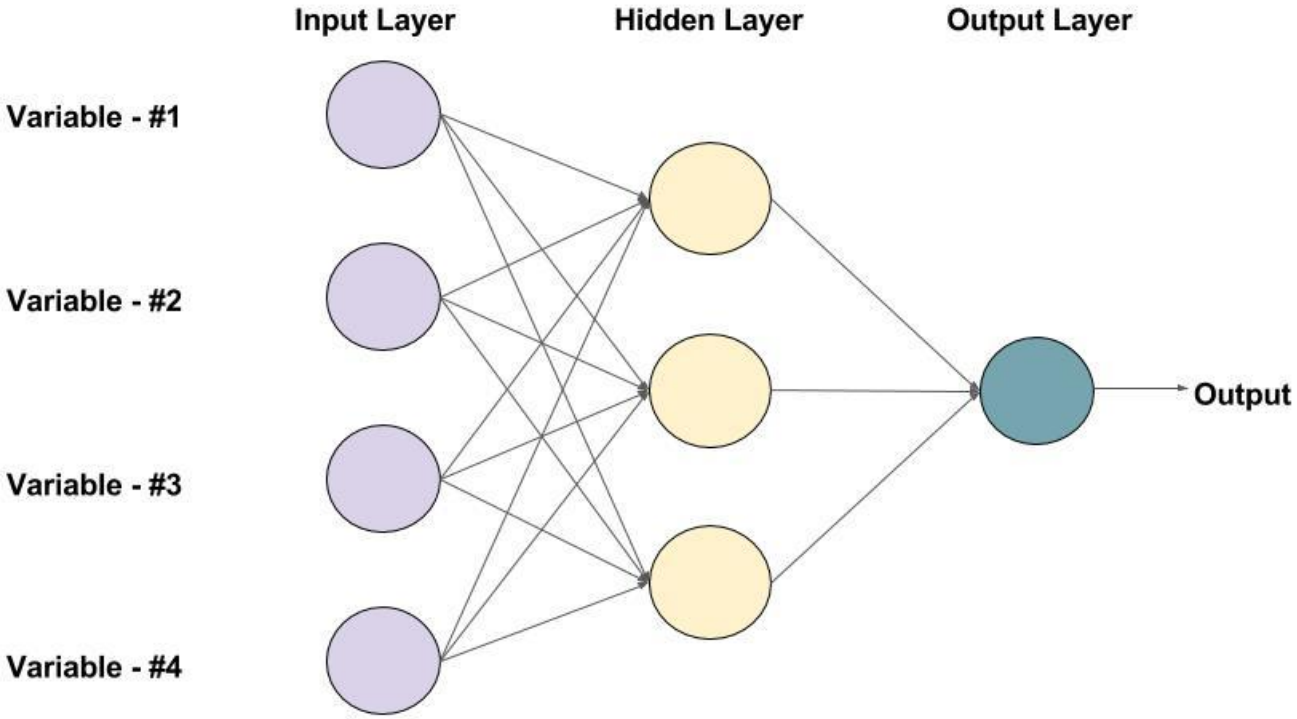
Często funkcja skokowa Heaviside'a

y^j = -1 gdy e <0
0 gdy e = 0
1 gdy e>0

Model neuronu

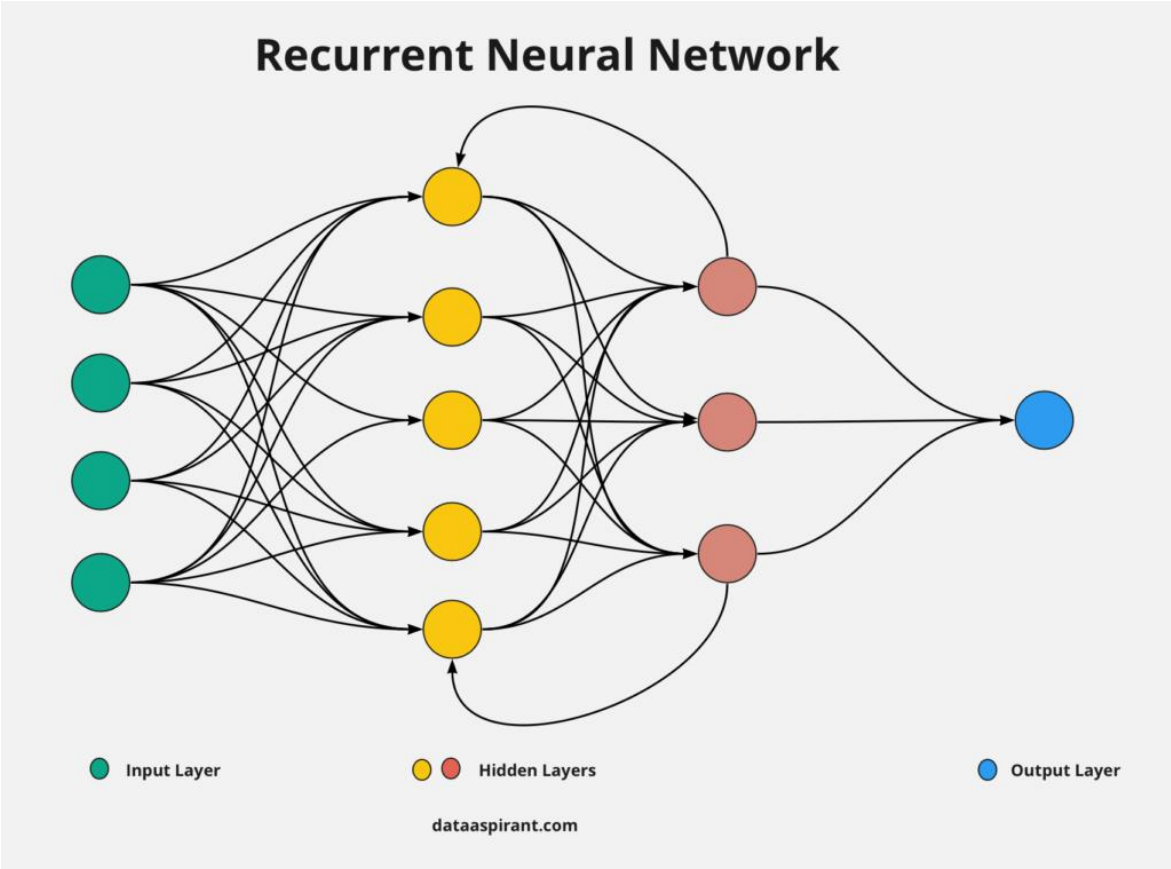


Sieć feed-forward



An example of a Feed-forward Neural Network with one hidden layer (with 3 neurons)

Sieć rekurencyjna



Rekurencyjne sieci neuronowe

-RNN przetwarza sekwencję danych krok po kroku, zapamiętując kontekst z poprzednich elementów. To czyni ją idealną do tekstu, mowy, muzyki czy szeregów czasowych.

Rekurencyjne sieci neuronowe

- **Mechanizm działania:**

Dla każdego kroku czasowego t:

$$h_t = f(W_x x_t + W_h h_{t-1} + b)$$

$$y_t = g(W_y h_t)$$

gdzie:

- x_t — aktualne wejście (np. słowo, znak),
- h_{t-1} — stan ukryty z poprzedniego kroku (pamięć),
- h_t — nowy stan ukryty (zaktualizowana pamięć),
- y_t — wyjście (np. przewidywane następne słowo),
- f, g — funkcje aktywacji (np. tanh, softmax).

Rekurencyjne sieci neuronowe

- Sieć „czyta” sekwencję jak człowiek zdanie - pamiętając kontekst poprzednich słów

- Przekazuje sobie stan pamięci z kroku na krok

- Typowe modele to LSTM i GRU z mechanizmami pamięci długoterminowej