Laboratorium nr 3 – Podstawowe algorytmy przetwarzania tekstu

Zadanie na 3.0

Opis: Pobierz tekst z zagranicznej literatury, np. *Hamleta* ze strony: `https://www.gutenberg.org/ebooks/27761`

Wybierz 5 zdań z wybranej pozycji literackiej. Wykonaj dla nich:

- tokenizację,
- stemming (1 wybrany algorytm),
- lematyzację (1 wybrany algorytm).

Porównaj osiągnięte wyniki.

Instrukcja oddania:

- Na teams prześlij archiwum
- Archiwum powinno zawierać:
  - wybrany plik `.txt` z tekstem literackim,
  - kody źródłowe w języku Python.

Zadanie na ocenę 3.0 nie wymaga odpowiedzi ustnej ze sprawozdania.

Zadanie na 4.0

Opis: Dla tekstu z literatury angielskiej:

- porównaj dwa stemmery.

Dodatkowo wykonaj porównanie:

- tokenizacji,
- stemmingu,
- lematyzacji

dla tekstu z literatury polskiej (wybierz dedykowane rozwiązania dla języka polskiego).

Instrukcja oddania:

- Na teams prześlij archiwum
- Archiwum powinno zawierać:
  - wybrany plik `.txt` z tekstem literackim,
  - kody źródłowe w języku Python,
  - sprawozdanie w formacie `.pdf`.

Sprawozdanie powinno zawierać:

1. Definicje wskazujące na różnice między stemmingiem i lematyzacją,
2. Krótkie podsumowanie wykorzystanych metod,
3. Porównanie uzyskanych wyników.

Po przesłaniu pliku `.zip` należy podejść do odpowiedzi ustnej na najbliższych laboratoriach.

Zadanie na 5.0

Opis: Porównaj n-gramy (do 4) ze stemmingiem i lematyzacją, a także z uwzględnieniem stopwords. Porównaj uzyskane histogramy z wynikami osiągniętymi w laboratorium nr 2.

Instrukcja oddania:

- Na teams prześlij archiwum
- Archiwum powinno zawierać:
  - wybrany plik `.txt` z tekstem literackim,
  - kody źródłowe w języku Python,
  - sprawozdanie w formacie `.pdf`.

Sprawozdanie powinno zawierać:

1. Definicje wskazujące na różnice między stemmingiem i lematyzacją,
2. Krótkie podsumowanie wykorzystanych metod,
3. Porównanie uzyskanych wyników.

Po przesłaniu pliku `.zip` należy podejść do odpowiedzi ustnej na najbliższych laboratoriach.
