Laboratorium nr 4 – Wektoryzacja tekstu i jego klasyfikacja

Zadanie na 3.0

Na platformie **Teams** znajduje się zbiór danych dotyczący detekcji spamu. Zbiór zawiera 83 446 próbek danych. Na potrzeby eksperymentów możesz wybrać podzbiór tego zbioru.

- Label 1 – oznacza spam
- Label 0 – normalna wiadomość

Twoim zadaniem jest:

1. Wczytanie tego zbioru danych,
2. Usunięcie stopwords,
3. Przeprowadzenie lematyzacji,
4. Wektoryzacja algorytmem **Doc2Vec**,
5. Budowa modeli klasyfikacyjnych rozpoznających spam.

Podziel zbiór danych na część uczącą (80%) i testową (20%). Wybierz trzy algorytmy klasyfikacji (na razie pomijamy wszelkiego rodzaju sieci neuronowe) z biblioteki `scikit-learn`. Dobierz parametry tych algorytmów za pomocą **grid search** lub **random search**.

Zbierz podstawowe metryki klasyfikacji, takie jak:

- accuracy,
- f1-score,
- precision,
- recall,

oraz przygotuj macierze pomyłek i krzywe ROC.

Na platformie **Teams** wyślij archiwum `LAB4_Nazwisko_Imie_Nazwisko_Imie.zip`, które powinno zawierać:

- kody źródłowe w języku Python,
- plik PDF zawierający wyniki modeli oraz rysunki krzywych ROC i macierzy pomyłek.

Zadanie na 3.0 nie wymaga odpowiedzi ustnej ze sprawozdania.

Zadanie na 4.0

Rozszerz eksperyment z wektoryzacją o wykorzystanie algorytmu **Word2Vec**, wraz z obraniem jednej ze strategii standaryzacji długości wektorów (np. jednej z tych przedstawionych na laboratoriach). Porównaj wyniki osiągnięte dla **Word2Vec** i **Doc2Vec**.

Wykorzystaj 5 modeli klasyfikacyjnych.

Na platformie **Teams** wyślij archiwum `LAB4_Nazwisko_Imie_Nazwisko_Imie.zip`, które powinno zawierać:

- kody źródłowe w języku Python,
- sprawozdanie w formacie PDF zawierające krótki opis zbioru danych, przeprowadzone eksperymenty i uzyskane wyniki.

Prześlij plik w terminie i przygotuj się do odpowiedzi ustnej na najbliższych laboratoriach.

Zadanie na 5.0

Rozszerz zadanie na 4.0 o dodatkowe eksperymenty związane z **analizą sentymentu**. Zbiór danych znajduje się na platformie **Teams** – celem przyspieszenia obliczeń możesz wykorzystać część tego zbioru.

Porównaj swoje modele z dedykowanymi rozwiązaniami typu `https://pypi.org/project/vaderSentiment/` (lub innym gotowym rozwiązaniem).

Na platformie **Teams** wyślij archiwum `LAB4_Nazwisko_Imie_Nazwisko_Imie.zip`, które powinno zawierać:

- kody źródłowe w języku Python,
- sprawozdanie PDF z opisem zbioru danych, przeprowadzonych eksperymentów i uzyskanych wyników.

Prześlij plik w terminie i przygotuj się do odpowiedzi ustnej na najbliższych laboratoriach.

Uwagi ogólne

W realizacji zadań można wykorzystać inne zbiory danych związane z detekcją spamu lub analizą sentymentu. Wiele takich zbiorów jest dostępnych m.in. na platformie **Kaggle**.